Стажировка	
«Веб-приложение для публикации постов – полнотекстовый поиск через postgres FTC»	
	Выполнил: Ноздряков Богдан Валериевич
	Проверил: Пармузин Александр Игоревич
Санкт-Петербург	

Условие:

Реализовать полнотекстовый поиск так, чтобы при наличии поста:

```
копировать [
```

Можно было осуществить поиск таким образом и найти этот пост:

```
копировать end postsApi?filters[title]=стены
```

Реализация через нативные средства на postgres – postgres FTC.

Анализ:

Полнотекстовый поиск (FTC):

-Перед тем, как разбираться что такое полнотекстовый поиск, важно разобрать следующие термины:

Документ — это некая единица обработки, например, статья, страница, или запись в базе данных, содержащая текстовые поля. Система поиска текста должна уметь разбирать документы и сохранять связи лексем (ключевых слов) с содержащим их документом. Впоследствии эти связи могут использоваться для поиска документов с заданными ключевыми словами.

Запрос – это текст, который мы ищем в документе. Может состоять из одного, или нескольких слов. Также может содержать логические операторы для более гибкого управления поиском.

Найденные документы соответствуют запросу. Однако понятие соответствия – очень размыто. Соответствие подразумевает, что в документе есть слова из теста запроса. Но также может учитываться частота повторения или то, на сколько близко стоят искомые слова друг к другу в тексте.

Стоп-слово – это такое слово, которое встречается во всех документах, и нет смысла искать по данному слову (предлоги, союзы, местоимения).

-Для того, чтобы реализовать механизм полнотекстового поиска, используя Postgres – существует два способа:

- Использование поисковых движков (Solr, elastic, Sphinx)
- Использование нативных средств

В текущей реализации – нужно реализовать полнотекстовый поиск, используя нативные средства Postgres. Из-за этого, мы не будем здесь разбирать способ через поисковые движки, а сосредоточимся на нативном Postgres.

-Итак, **полнотекстовый поиск** (или просто поиск текста) — это возможность находить документы на естественном языке, соответствующие запросу, и, возможно, дополнительно сортировать их по релевантности для этого запроса.

Сразу нужно пояснить, что возможность находить документы на естественном языке — имеется в виду, что поиск осуществляется с использованием обычных, повседневных выражений и фраз, которые люди используют в общении, а не специфических кодов или команд. Это отличает полнотекстовый поиск от других видов поиска, где могут потребоваться специальные запросы или синтаксис. Например, вместо использования сложных запросов на языке SQL для поиска информации в базе данных, пользователь может просто ввести фразу или слово на своем родном языке, и система найдет соответствующие документы или записи.

Сортировать по релевантности — имеется в виду, что найденные документы или записи будут упорядочены в соответствии с тем, насколько хорошо они соответствуют поисковому запросу пользователя. Релевантность определяется на основе различных факторов, таких как частота вхождения поисковых слов в документ, их расположение (например, наличие в заголовке или начале документа), а также другие параметры, которые могут учитываться поисковой системой или базой данных. Таким образом, документы, которые наиболее точно соответствуют запросу пользователя, будут отображаться первыми в результатах поиска.

- -То есть, когда пользователь ищет товары в интернет-магазине, статьи в блоге и т.д. по текстовому запросу, как, например, в браузерах (Google, Yandex и т.д.) или в YouTube это все полнотекстовый поиск.
- -Среди механизмов текстового поиска в Postgres можно выделить следующие компоненты:
 - Анализаторы
 - Словари
 - Конфигурации

Разберем каждый из них:

1) Анализатор – разделяет документы на фрагменты и классифицирует их:

```
Хлеб да вода – здоровая еда → 

'вода': 3, 'еда': 5, 'здоровая': 4, 'хлеб': 1, 'да': 2
```

2) Словарь – преобразует фрагменты в лексемы, приводит их к нормализованному виду, удаляет стоп-слова:

```
Хлеб да вода – здоровая еда →

'вода': 3, 'еда': 5, 'здоровая': 4, 'хлеб': 1, 'да': 2 →

'вода': 3, 'еда': 5, 'здоровая': 4, 'хлеб': 1
```

3) Конфигурация — задает связку анализатора с набором словарей, которые будут обрабатывать выделенные фрагменты (postgresql.conf). Для каждого типа фрагментов в конфигурации присваивается отдельный список словарей. Фрагмент последовательно проходит через все словари, пока в каком-либо из них слово не будет найдено. Если это стоп-слово, или ни один словарь не смог его распознать, то фрагмент не будет учитываться при индексации

То есть текстовый поиск позволяет: пропускать определенные слова (стоп-слова), обрабатывать синонимы и выполнять сложный анализ слов, например, выделять фрагменты не только по пробелам. Все эти функции управляются конфигурациями текстового поиска. Можно как использовать существующие конфигурации, так и писать свои.

Для упрощения создания конфигураций текстового поиска, они строятся из более простых объектов. В PostgreSQL есть четыре типа таких объектов:

- Анализаторы текстового поиска разделяют документ на фрагменты и классифицируют их (например, как слова или числа)
- Словари текстового поиска приводят фрагменты к нормализованной форме и отбрасывают стоп-слова
- Шаблоны текстового поиска предоставляют функции, образующие реализацию словарей (при создании словаря просто задается шаблон и набор параметров для него)

• Конфигурации текстового поиска — выбирают анализатор и набор словарей, который будет использоваться для нормализации фрагментов, выданных анализатором

Анализаторы и шаблоны текстового поиска строятся из низкоуровневых функций на языке С

Основные типы данных:

- tsvector нужен для хранения подготовленных документов (создает лексемы). Для нужд текстового поиска каждый документ должен быть сведен к специальному формату tsvector. Поиск и ранжирование выполняются исключительно с этим представлением документа исходный текст потребуется извлечь, только когда документ будет отобран для вывода пользователю. Поэтому под tsvector часто подразумевается документ, тогда как этот тип, конечно, содержит только компактное представление всего документа.
- tsquery для представления обработанных запросов

С этими типами работает целый ряд функций и операторов, и наиболее важный из них – оператор соответствия @ @.

-Разберем теперь как строятся индексы:

Полнотекстовая индексация заключается в предварительной обработке документов и сохранения индекса для последующего быстрого поиска.

То есть если мы хотим ускорить поиск, то в определенных случаях поможет индексация. Она будет включать в себя:

- Разбор документов на фрагменты (подстроки текста документа). Это функцию выполняет анализатор. При этом, можно как использовать встроенный анализатор, так и написать свой узконаправленный
- Преобразование фрагментов в лексемы (слова, имеющие ценность для индексации и поиска). Этот шаг выполняют словари. Можно использовать существующие словари, а также писать свои
- Хранение преобразованных документов, подготовленных для поиска. Например, каждый документ может быть представлен в виде сортированного массива нормализованных лексем. Помимо лексем часто желательно хранить информацию об их положении для ранжирования по близости, чтобы документ, в котором слова расположены "плотнее", получал более высокий рейтинг, чем документ с разбросанными словами

Лексема — это нормализованный фрагмент, в котором разные словоформы приведены к одной. Например, при нормализации буквы верхнего регистра приводятся к нижнему, а из слов обычно убираются окончания. Благодаря этому можно находить разные формы одного слова, не вводя вручную все возможные варианты. Кроме того, на данном шаге обычно исключаются стоп-слова.

B Postgres для полнотекстового поиска существуют индексы двух видов:

- GIN рассчитан на случаи, когда чаще выполняется чтение, а не запись. Хранит не записи целиком, а отдельные лексемы со списком места вхождения. Лексемы структурированы в виде b-дерева.
- GIST наоборот, когда нужно больше записывать в базу данных, чем читать. Данный индекс быстро обновляется, но из-за особенностей его реализации, поиск с таким индексом допускает неточности, которые Postgres исправляет дополнительными проверками. Из-за этого поиск идет дольше. Основан на хэш-таблицах

Рассмотрим, как строится индекс GIN на следующем примере:

```
Хлеб да вода — здоровая еда. У кого работа, у того и хлеб.
```

```
Слово к ответу, а хлеб – к обеду. Работа не волк – в лес не убежит.
```

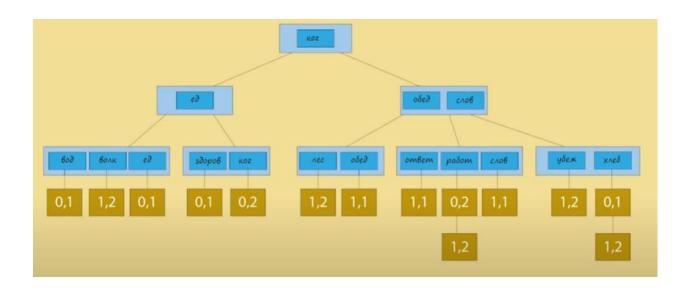
Преобразованные к типу tsvector – они будут выглядеть так:

```
0,1 'вод': 3, 'ед': 5, 'здоров': 4, 'хлеб': 1
0,2 'ког': 2, 'работ': 3, 'хлеб': 7
1,1 'обед': 7, 'ответ': 3, 'слов': 1, 'хлеб': 5
1,2 'волк': 3, 'лес': 5, 'работ': 1, 'убеж': 7
```

Во внутреннем представлении записей базы данных имеются уникальные идентификаторы TID: $\{[0,1],[0,2],[1,1],[1,2]\}$

Они состоят из номера блока и номера строки в блоке.

-Внутри Postgres созданный индекс будет иметь вид b-дерева, в узлах которого находятся лексемы, а к листьям крепятся списки TID:



-Полнотекстовый поиск – это не только получения документов, соответствующих запросу, но и возможность оценить, где это соответствие больше, а где меньше – проранжировать результаты.

Ранжирование — это сортировка по степени соответствия запросу, то есть по релевантности. Для ранжирования используется функция ts_rank. Для назначения tsvector элементам разных весов — используется функция setweight. Вес элемента задается буквами A, B, C и D. Обычно это применяется для обозначения важности слов в разных частях документа от самого важного до наименее важного, где A — самый важный, D — самый неважный. Затем эта информация может использоваться при ранжировании результатов поиска.

Преимущества FTC:

- FTC поддерживает лингвистический функционал. Становится возможным работа с различными формами слов и с синонимами
- FTC делает возможным получение результатов поиска на основе их релевантности запросу, что очень эффективно, когда имеется сотни подходящих документов
- FTC позволяет быстрее получать данные за счет возможности использовать индексирования
- FTC позволяет получает данные более оптимизированным способом за счет различных техник, например, удаление стоп-слов, стемминг и т.д.

Недостатки FTC:

- Внедрение и настройка FTC может оказаться довольно сложной, особенно для достижения высокой производительности на больших объемах данных
- FTC требователен к ресурсам системы из-за необходимости обрабатывать и анализировать большие объемы текстовых данных

Поиск текста через SQL:

-Для того, чтобы реализовать текстовый поиск в базе данных – можно просто использовать SQL. Для этого существуют следующие операторы:

- ~
- ~*
- LIKE
- ILIKE

Операторы LIKE и ILIKE используются для поиска подстрок внутри текстовых строк. LIKE чувствителен к регистру, в то время как ILIKE – нет. Они поддерживают символы % (для совпадения с любым числом символов) и _ (для совпадения с одним символом). Эти операторы хорошо подходят для простых запросов, когда нужно найти строки, содержащие определенные фрагменты текста.

Операторы ~ и ~* используются в PostgreSQL для выполнения регулярных выражений. Оператор ~ чувствителен к регистру, а ~* - нет. Данные операторы позволяют сделать в разы больше, чем операторы LIKE и ILIKE, но они требуют глубоких знаний регулярных выражений. Также писать регулярные выражения может быть неэффективно, особенно при создании сложных запросов (очень тяжело предусмотреть и описать все случаи для сложного запроса через одни регулярные выражения), а также при работе с большим текстовым объемом (будет очень страдать производительность).

Также данные операторы не поддерживают лингвистический функционал. Даже регулярные выражения очень ограничены — они не рассчитаны на работу со словоформами — например, "подходят" и "подходить". С ними возможно пропустить документы, которые содержат "подходят", но, вероятно, и они представляют интерес при поиске по ключевому слову "подходить". Конечно, можно попытаться перечислить в регулярном выражении все варианты слова, но это будет очень трудоёмко и подвержено ошибкам, так как некоторые слова могут иметь десятки словоформ.

Преимущества поиска текста через SQL:

- Операторы SQL для поиска текста легко внедрять и использовать
- Данные операторы очень хороши именно для определенного случая когда поиск текста осуществляется через простые запросы, где не требуется поддержки лингвистического функционала, не требуется работы с большими текстовыми объемами, не требуется упорядочивать результаты поиска по релевантности здесь данные операторы очень подходят. И в таким случаях наилучшим решением будет использовать именно данные операторы

Недостатки поиска текста через SQL:

- Такой метод не поддерживает поиск по формам слова. Конечно, можно использовать регулярные выражения, но придется пересмотреть десятки вариантов, что весьма трудоемко, а также легко ошибиться
- Полученные результаты не будут отсортированы по релевантности
- Поиск будет идти медленно, потому что нет полноценной индексной поддержки при каждом поиске придется просматривать все документы

Отличие FTC от поиска текста через SQL:

- -Отличие двух этих методов заключается в их подходах к поиску и обработке текстовых данных. Вот основные различия:
 - FTC использует лингвистический анализ для улучшения поиска, в то время, как операторы SQL работают с текстом прямолинейно, без учета морфологии или контекста слова
 - FTC позволяет использовать ранжирование результатов по их совпадению запросу, чего не могут операторы SQL
 - Операторы SQL позволяют реализовать поиск по шаблонам с небольшими объемами данных, а также простыми запросами
 - FTC позволяет реализовать сложные запросы с большими объемами текстовых данных
 - FTC лучше в плане производительности, за счет его механизмов поиска

Итог:

-Было рассмотрено два способа поиска текста — Postgres FTC и операторы SQL (операторы LIKE, ILIKE, ~, ~*). Выбор метода зависит от требований к приложению. Если в приложении нужен функционал, при котором следует искать простые подстроки без учета морфологии или текста, когда работа идет с маленьким объемом данных и простыми запросами, то в таком случае оптимальным решением будет использование операторов SQL, то есть операторов LIKE, ILIKE, ~, ~*. Однако если же приложение требует более сложного функционала — работа с большими текстовыми полями, нужно учитывать различные формы слова или искать синонимы, нужно ранжировать результаты поиска по их совпадению с запросом, нужна лучшая производительность, то в таком случае SQL просто не предоставляет решения для реализации заданного функционала. В таком случае — нужно реализовывать FTC.

Решение:

- -Полнотекстовый поиск будет использоваться только для таблицы постов пользователей Post. Для всех остальных таблиц: User, UserContact, Subscription при соответствующем методе поиска текста, будет по-прежнему использован оператор LIKE. Такое решение было принято, так как большие данные есть только в таблице Post это колонка content, отвечающая за содержимое поста. Также при поиске текста в постах важно поддерживать поиск различных форм слов, а также выдачу результатов по их степени соответствия запросу. Во всех остальных же таблицах при соответствующих методах поиска текста, будет происходить работа с маленькими данными, где не требуется ранжировка по релевантности, а также не нужно учитывать морфологию и контекст слова. Здесь нужен простой поиск заданной подстроке в небольшом тексте, с чем прекрасно справится оператор LIKE.
- -Для реализации полнотекстового поиска сначала нужно выбрать колонки из базы данных, по которым будет осуществляться поиск. В нашем случае полнотекстовый поиск можно будет проводить по title, или content, или сразу по title и content (title и content колонки таблицы Post).
- -Для выполнения полнотекстового поиска, нужно отправить соответствующий SQL-запрос. Данный SQL-запрос всегда должен сопоставлять поисковой вектор с запросом. В таком случае это будет полнотекстовый поиск. Поисковой вектор это тип tsvector, который мы ранее разобрали (Напомню, чтобы реализовать полнотекстовый поиск сначала нужно выбрать колонки из базы данных, по которому будет идти поиск, затем преобразовать эти колонки к типу tsvector, который является массивом лексем с информацией об их позиции, а после сопоставлять этот tsvector с запросом, каждый раз, когда данный запрос приходит). Чтобы создать поисковой вектор tsvector, существует специальная команда to_tsvector. В нашей реализации полнотекстовый поиск осуществляется по колонкам title и content. Чтобы нам каждый раз, когда пользователь захочет выполнить полнотекстовый поиск, не пришлось приводить title и content к типу tsvector создадим специальную колонку text_tsv в таблице Post. Данная колонка будет

содержать title и content, приведенные к типу tsvector. В таком случае – когда пользователь захочет выполнить полнотекстовый поиск, нам будет достаточно сопоставить запрос с колонкой text_tsv, и не нужно будет выполнять операцию to_tsvector перед сопоставлением.

-Чтобы реализовать данную логику, напишем миграцию, которая все это реализует (./src/database/migrations/20240719151942-add_text_tsv_column_to_post_table.js):

В функции ир данной миграции, мы сначала проверяем — существует ли в таблице Post колонка text_tsv. Если такой колонки не существует, то мы ее создаем для таблицы Post. После создания данной колонки, у всех существующих данных — колонка text_tsv будет равна null. Нужно это исправить:

Как уже было сказано panee – text_tsv должен содержать поисковой вектор tsvector, основанный на колонках title и content. Здесь мы для всех записей, которые уже существуют в таблице Post – изменяем колонку text_tsv следующим образом:

- to_tsvector('russian', "title") преобразуем запись title к типу tsvector, указывая, что текст должен быть обработан с учетом особенностей русского языка
- setweight(to_tsvector('russian', "title"), 'A') устанавливаем вес А для полученных от to_tsvector('russian', "title") лексем. Таким образом, мы устанавливаем метку о том, что все лексемы, связанные с заголовком поста являются самыми важными (это можно использовать при ранжировании)

- to_tsvector('russian', "content") преобразуем запись content к типу tsvector, указывая, что текст должен быть обработан с учетом особенностей русского языка
- setweight(to_tsvector('russian', "content"), 'B') устанавливаем вес В для полученных от to_tsvector('russian', "content") лексем. Таким образом, мы устанавливаем метку о том, что все лексемы, связанные с текстом поста являются вторыми по важности, после лексем-заголовков (это можно использовать при ранжировании)
- setweight(to_tsvector('russian', "title"), 'A') || setweight(to_tsvector('russian', "content"), 'B') объединяем полученные лексемы-заголовки с полученными лексемами-текстами

Таким образом, мы запишем для каждой записи в таблице Post, новое значение колонки text_tsv - приведенные к tsvector колонки: title и content.

- -Теперь мы сможем использовать text_tsv каждый раз, когда пользователь захочет выполнить полнотекстовый поиск. При этом нам не нужно будет выполнять to_tsvector перед сопоставлением. Однако есть важный нюанс пользователь может изменить свой пост. В том числе, он может изменить title и content поста. В таком случае нужно будет также изменить и text_tsv поста, так как он строится на данных title и content. Также пользователь может создать новый пост, поэтому нужно будет заполнить text_tsv нового поста, поскольку оно будет содержать значение null после создания (нет значения по умолчанию).
- -Чтобы решить этот вопрос создадим триггер через данную миграцию, который будет обновлять text_tsv посту, если пользователь изменяет title или content посту, либо же пользователь пытается создать новый пост:

Здесь мы создаем функцию update_text_tsv, которую будет использовать триггер для обновления text_tsv. В данной функции есть условие проверки:

IF NEW.title IS NOT NULL OR NEW.content IS NOT NULL

эта проверка нужно для случая, когда пользователь обновляет пост. Здесь проверяется – изменяет ли пользователь title или content. Если хоть что-то из этого изменяется, то в таком случае text_tsv обновляется на основе новых значений title и content:

```
NEW.text_tsv := setweight(to_tsvector('russian', NEW.title), 'A') || setweight(to_tsvector('russian', NEW.content), 'B')
```

Если же ни title, ни content не обновляются, то в таком случае не обновляется и text_tsv. В случае, когда пользователь будет создавать новый пост – title и content точно будут заданы. Поэтому это условие выполнится и text_tsv заполнится соответствующим образом.

Дальше создадим сам триггер:

```
await queryInterface.sequelize.query(`
    CREATE TRIGGER update_text_tsv_trigger
    BEFORE INSERT OR UPDATE ON \"Posts\"
    FOR EACH ROW EXECUTE PROCEDURE update_text_tsv();
    `);
```

Данный триггер update_text_tsv_trigger — будет выполнять созданную ранее функцию update_text_tsv, если в таблицу Post добавляется новая запись, или изменяется старая. Причем, функция update_text_tsv отработает до создания поста, либо же до изменения поста.

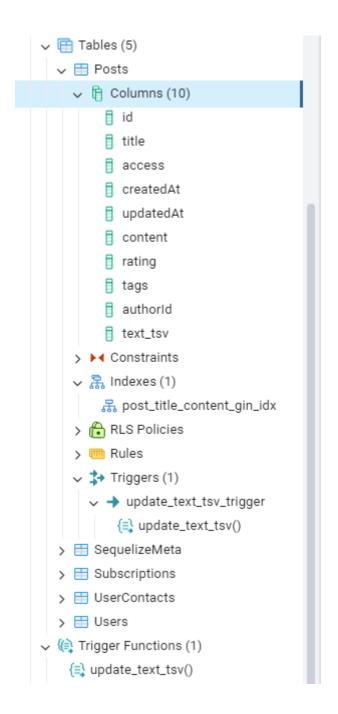
-После создания триггера обновления text_tsv — осталось предусмотреть оптимизацию поиска. Как было описано ранее — для этого существуют индексы. То есть нам нужно создать индекс GIN для колонки text_tsv, чтобы полнотекстовый поиск выполнялся быстрее. Для этого добавим в нашу миграцию также и создание индекса:

Здесь мы создали индекс GIN post_title_content_gin_idx для колонки text_tsv. Я решил использовать именно GIN, а не GIST, так как GIST работает дольше, чем GIN.

-В конце осталось только определить down нашей миграции, где мы будем удалять все созданное в up: колонку text_tsv, функцию update_text_tsv, триггер update_text_tsv_trigger и индекс post_title_content_gin_idx:

```
async function down({ context: queryInterface }) {
  const tableInfo = await queryInterface.describeTable('Posts');
  if (tableInfo.text_tsv) {
    await queryInterface.dropTrigger('Posts', 'update_text_tsv_trigger');
    await queryInterface.removeIndex('Posts', 'post_title_content_gin_idx');
    await queryInterface.removeColumn('Posts', 'text_tsv');
    await queryInterface.dropFunction('update_text_tsv', []);
}
```

-Мы создали миграцию. Теперь применим ее и убедимся, что все было добавлено правильно:



Как можно заметить, все данные были успешно добавлены в таблицу Post: колонка text_tsv, функция update_text_tsv, триггер update_text_tsv_trigger и индекс post_title_content_gin_idx.

-После успешного применения данной миграции — необходимо также добавить text_tsv в модель Post (./src/database/models/post/post.model.ts) для корректной работы Sequelize:

```
@Column({
   type: DataType.TSVECTOR,
   allowNull: true
})
text_tsv?: string | null | undefined;
```

-Сейчас мы добавили в таблицу Post колонку text_tsv, которая содержит tsvector колонок, по которым будет выполняться полнотекстовый поиск. Мы настроили text_tsv на автоматическое обновление через триггер в случае, если изменятся данные колонок, на которых основан text_tsv или создастся новая запись, содержащая text_tsv. Мы добавили индекс GIN для text_tsv для обеспечения быстрого поиска. Теперь нам необходимо принимать запросы от пользователя на полнотекстовый поиск и выполнять их. Для этого нужно изменить контроллер PostController (./src/domain/post/post.controller.ts). Однако перед тем, как переходить к изменению контроллера, также потребуется изменить другие части ПО:

1. Нужно изменить метод GET для /api/posts/public (Get all user posts) в Swagger-документации (./src/middleware/swagger/swagger.yaml):

```
| decorate | decorate
```

По заданию – пользователь может решать по какой колонке проводить полнотекстовый поиск:

```
копировать • • postsApi?filters[title]=стены
```

Поэтому нужно изменить метод получения всех постов в Swagger-документации так, чтобы он предоставлял возможность производить поиск по определенной

колонке. Здесь мы именно это и сделали – добавили в параметры дополнительное поле – searchParam, которое может принимать только два значения: 'title' или 'content'. Теперь в Swagger-документации – можно отправлять запрос на полнотекстовый поиск постов, выбирая колонку для поиска. Если в searchParam указать 'title', то полнотекстовый поиск будет проходить только по колонке title. Если же указать в searchParam 'content', то полнотекстовый поиск будет проходить только по колонке content. Если же вообще ничего не указывать в searchParam, то полнотекстовый поиск будет проходить и по 'title', и по 'content'

2. В контроллере нам потребуется написать SQL-запрос, в котором будет происходить сопоставление поискового вектора с запросом. Если не использовать "сырой" SQL, а использовать метод FindAll Sequelize, то в таком случае существует единственный способ написать такой запрос — передать в объект where метода FindAll литерал Sequelize, в котором будет прописан данный SQL-код. Мы воспользуемся как-раз таким способом — использование метода FindAll Sequelize вместо "сырого" SQL-запроса. Для этого нам нужно изменить сервис PostService (./src/domain/post/post.service.ts) таким образом, чтобы он правильно внедрял литерал Sequelize в объект для метода FindAll:

```
private setupFindOptions(
  findOptions: FindOptions,
  user: IUserPayload | undefined,
  literalQuery: string | undefined
) {
  if (user) {
    findOptions = this.findOptionsRoleFilter(findOptions, user);
  }
  if (literalQuery) {
    findOptions = this.findOptionsJoinLiteral(findOptions, literalQuery);
  }
  return findOptions;
}
```

```
public async getAllUserPosts(
   findOptions: FindOptions,
   user?: IUserPayload,
   literalQuery?: string
): Promise<Post[]>
{
   findOptions = this.setupFindOptions(findOptions, user, literalQuery);
   const posts = await Post.findAll(findOptions);
   return posts;
}
```

Была добавлена новая функция findOptionsJoinLiteral, которая безопасно внедряет написанный литерал Sequelize в объект findOptions для метода findAll Sequelize. Также была добавлена новая функция setupFindOptions, которая будет настраивать соответствующим образом объект findOptions (добавлять туда данные на основе ролей пользователя если нужно, встраивать туда литерал Sequelize если нужно). Данный метод просто выносит логику настройки объекта findOptions для методов Sequelize, чтобы не пришлось в методах сервиса повторно писать настройку findOptions. Также был изменен сам метод getAllUserPosts. Этот метод будет использоваться, когда пользователь будет проводить полнотекстовый поиск по постам. Данный метод теперь принимает необязательный параметр literalQuery, который будет представлять из себя написанный литерал Sequelize. Дальше метод настроит объект findOptions через setupFindOptions, а после настройки – выполнит метод Sequelize FindAll на основе данного findOptions и вернет массив постов.

3. Теперь можно изменять сам PostController. Сначала добавим поле searchParamWeightSettings:

```
private readonly searchParamWeightSettings = {
   title: 'A',
   content: 'B'
};
```

Данное поле будет служить конфигуратором для фильтрации поиска по определенной колонке. После изменим метод getAllUserPosts, который возвращает все посты пользователя. Именно данный метод позволяет выполнить полнотекстовый поиск:

```
public async getAllUserPosts(req: Request, res: Response, next: NextFunction): Promise<Response | void> {
   const user = req.user as IUserPayload;
   const searchParam = req.query.searchParam;
   let searchSubstring = req.query.searchSubstring;
   let posts = [];
   if (!searchSubstring) {
     posts = await this.postService.getAllUserPosts({}, user);
     searchSubstring = (searchParam === 'title' || searchParam === 'content') ?
       `${searchSubstring}:${this.searchParamWeightSettings[searchParam]}`:
       searchSubstring;
     posts = await this.postService.getAllUserPosts(
         order: [
            Sequelize.literal(`ts_rank(text_tsv, to_tsquery('russian', '${searchSubstring}'))`),
       user,
       return res.status(200).json({ status: 200, data: posts, message: "List of all posts" });
   next(err);
```

Здесь:

• Получаем пользователя user, который выполняет метод, получаем параметр запроса searchParam, который задает колонку поиска, получаем подстроку запроса searchSubstring для полнотекстового поиска, которую будем искать в базе данных, а также определяем массив постов, который вернем пользователю после поиска:

```
const user = req.user as IUserPayload;
const searchParam = req.query.searchParam;
let searchSubstring = req.query.searchSubstring;
let posts = [];
```

• Дальше мы проверяем – задана или нет подстрока для поиска – if (!searchSubstring). Если она не задана, то это означает, что пользователь не применяет полнотекстовый поиск, а просто хочет получить список всех своих постов. В таком случае – выполняется соответствующий запрос:

```
posts = await this.postService.getAllUserPosts({}, user);
```

После выполнения данного запроса – пользователю вернется полученный результат.

Если же подстрока searchSubstring для поиска задана, то это означает, что пользователь хочет выполнить полнотекстовый поиск по данной подстроке. В таком случае — создается специальный запрос:

Здесь сначала проверяется – как пользователь хочет выполнить полнотекстовый поиск:

```
searchSubstring = (searchParam === 'title' || searchParam === 'content') ?
  `${searchSubstring}:${this.searchParamWeightSettings[searchParam]}`:
  searchSubstring;
```

Если в searchParam был установлен 'title', то пользователь хочет выполнить полнотекстовый поиск только по колонке 'title'. Если же в searchParam был установлен 'content', то пользователь хочет выполнить полнотекстовый поиск только по колонке 'content'. Напомню, что в векторе поиска text_tsv записаны лексемы как для title, так и для content. Соответственно, если мы хотим выполнить поиск только по title, то нужно получить из text_tsv только лексемы title, и наоборот для content. В этом нам помогут весы лексем — одна из причин, по который мы устанавливали в миграции веса A, B для лексем через setweight. Мы воспользуемся метками полнотекстового поиска. Например, если пользователь ищет по слову "работа" и хочет искать именно в лексемах с весом A, то нам достаточно просто передать в запрос следующее:

"работа:А"

Таким образом, запрос будет искать именно по лексемам с весом A. Аналогично будет для весов B, C и D.

Напомню, что мы установили для лексем title вес A, а для лексем content вес B.

Именно данную логику мы здесь и реализуем:

```
searchSubstring = (searchParam === 'title' || searchParam === 'content') ?
  `${searchSubstring}:${this.searchParamWeightSettings[searchParam]}`:
  searchSubstring;
```

B searchSubstring добавляется метка за счет использования конфигурации searchParamWeightSettings (именно поэтому мы создали такую конфигурацию, и именно поэтому мы создали ее именно такой).

Стоит отметить, что добавлять метки в поиске — это накладно в плане производительно. Однако производительность не должна пострадать, так как мы добавили для text_tsv индекс GIN.

Если же пользователь не захотел искать по конкретной колонке, а захотел искать сразу по двум колонкам, то в таком случае в searchSubstring не будет добавлено метки.

Дальше выполняется сам запрос:

Здесь создается литерал Sequelize:

```
'text tsv @@ to tsquery('russian', '${searchSubstring}')'
```

Именно данный код отвечает за полнотекстовый поиск в SQL-запросе. Здесь мы берем колонку text_tsv типа tsvector, которая содержит лексемы для поиска. Также мы преобразуем строку поиска searchSubstring к tsquery:

```
to tsquery('russian', '${searchSubstring}')
```

Это специальный тип, к которому нужно привести строку запроса, чтобы ее можно было сопоставить с вектором поиска.

Дальше просто происходит сопоставление вектора поиска text_tsv с запросом за счет оператора сопоставления @@. За счет этого — получается находить нужные записи из базы данных, которые совпадают с запросом, через полнотекстовый поиск.

Сервис дальше встроит этот литерал Sequelize в WHERE запроса.

Также мы указывает order:

Он нужен, чтобы проранжировать по релевантности результаты. Для этого используется ts_rank. Эта функция принимает вектор сопоставления и запрос. Она высчитывает коэффициент релевантности для каждого результата. Соответственно поэтому мы используем литерал Sequelize для вычисления ts_rank каждому результату в совокупности с ORDER BY DESC. То есть для каждого результата вычислится коэффициент релевантности, а затем с помощью ORDER DESC — результаты отсортируются по убыванию (то есть от результата с наибольшим коэффициентом релевантности до результата с наименьшим коэффициентом). Сервис вставит это в запрос следующим образом:

ORDER BY ts_rank(text_tsv, to_tsquery('russian', '\${searchSubstring}')) DESC

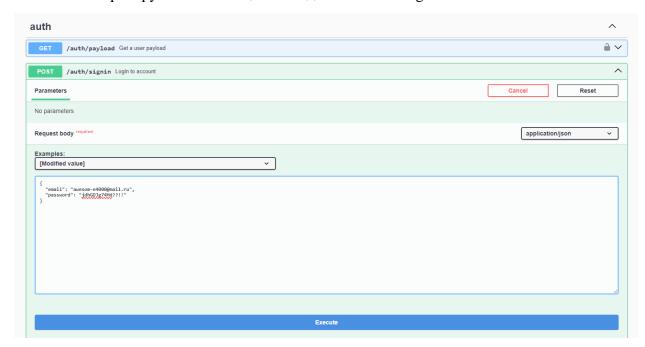
Также еще здесь мы передаем в сервис объект пользователя user, чтобы выдавать данные пользователю на основе его роли:

Таким образом мы создаем SQL-запрос, который выполнит полнотекстовый поиск на основе запроса пользователя и вернет результат.

Тестирование:

-Проведем тестирование внедренного функционала полнотекстового поиска постов. Для тестирования воспользуемся OpenApi-спецификацией Swagger. Запустим приложение и перейдем к документации Swagger (http://localhost:5000/api).

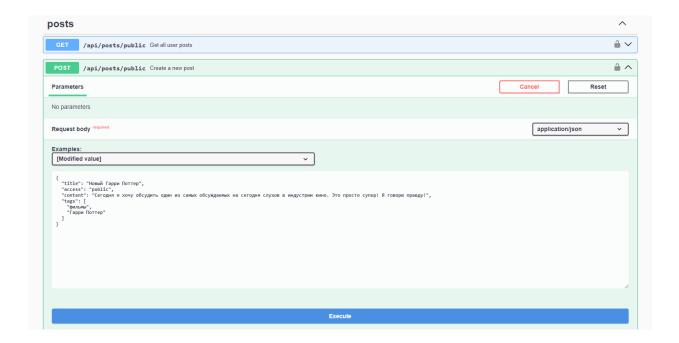
-Сначала авторизируемся с помощью метода POST /auth/signin:

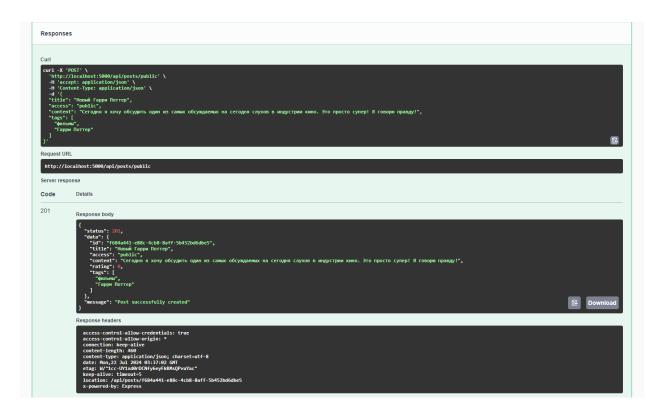




Мы успешно авторизировались.

-Теперь создадим новый пост пользователю с помощью метода POST /api/posts/public. Здесь мы проверим работу триггера — после создания поста, у него должен обновиться соответствующим образом text_tsv:



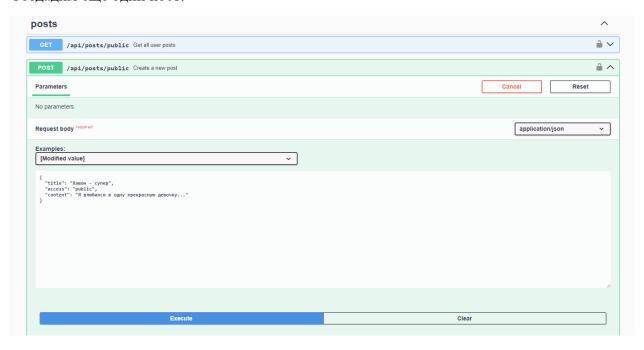


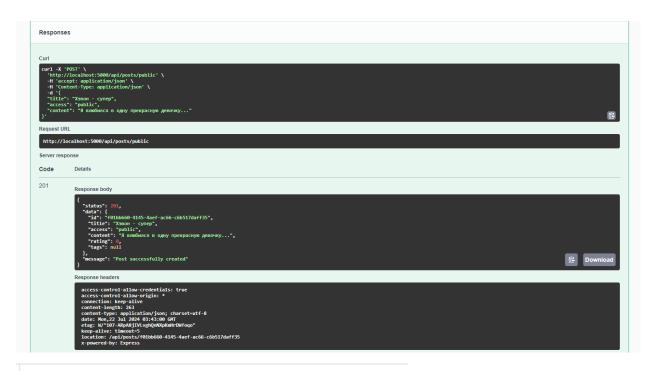
Как можно заметить — пост успешно создался. Теперь проверим — обновился ли в базе данных text_tsv для этого поста:

"rapp":2A 'rosop":22B 'индустр":16B 'кин":17B 'нов":1A 'обсуд":7B 'обсужда":11B 'поттер":3A 'правд":23B 'прост":19B 'сам":10B 'сегодн":48,13B 'слух":14B 'супер":20B 'хоч":6B 'з...

text_tsv успешно обновился для новой записи. Это означает, что тригтер при создании новой записи в таблице Post отработал правильно.

Создадим еще один пост:

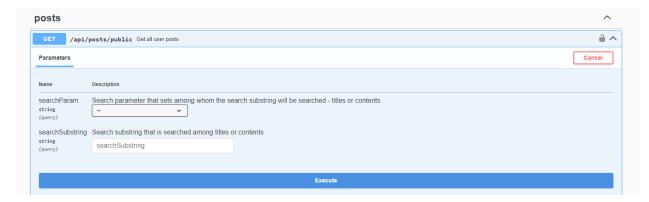




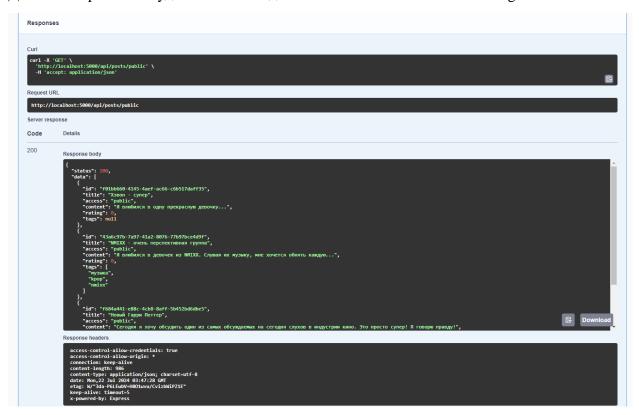
'влюб':4В 'девочк':8В 'одн':6В 'прекрасн':7В 'супер':2А 'хэвон':1А

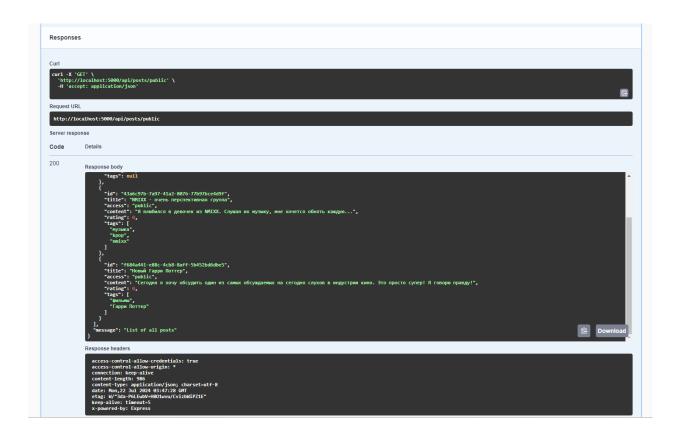
Еще один пост также создался успешно и text_tsv также обновился должным образом в базе данных. Значит триггер при создании новой записи в таблице Post – работает правильно.

-Теперь попробуем выполнить сам полнотекстовый поиск с помощью метода GET /api/posts/public. Для начала получим список всех постов пользователя (без полнотекстового поиска):



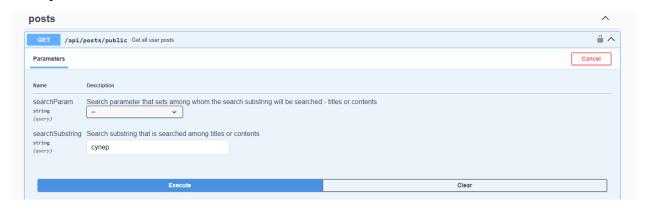
Для этого просто не будем ничего вводить в searchParam и searchSubstring:





Мы получили все посты пользователя. Значит все работает правильно.

-Теперь выполним полнотекстовый поиск:



Для выполнения полнотекстового поиска просто введем в searchSubstring значение. Также не будем ничего вводить в searchParam. Если задан searchSubstring, а searchParam не задан, то поиск будет проходить по title, и по content:

```
Responses

Curl

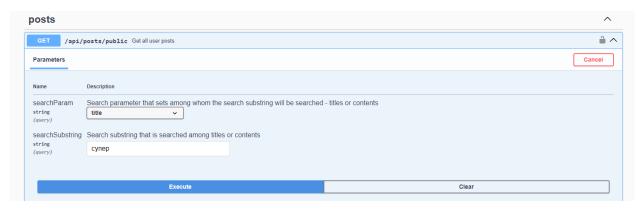
(set 3 * GET *)

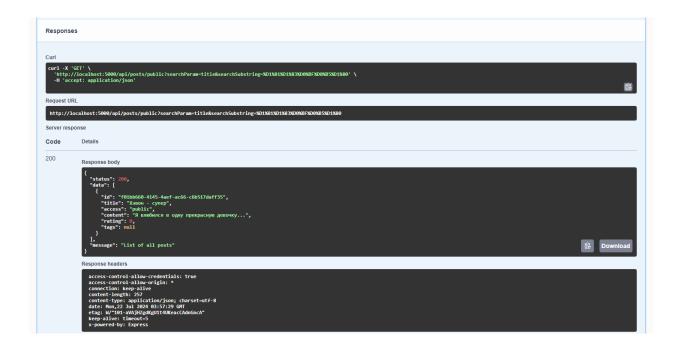
(http://acalasts/sem/deposts/public/search/sobstring-MOINSINDINGSNOMERROMERSON/SEM *)

(if except spillcafe of spi
```

Метод отработал верно — мы получили два поста: в одном подстрока "супер" находится в title, а в другом подстрока "супер" находится в content.

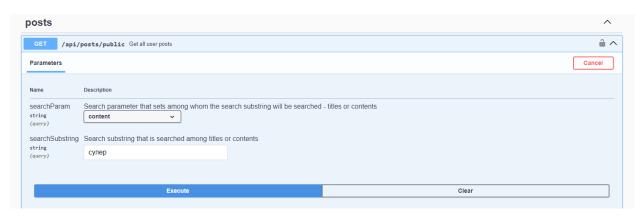
Теперь выполним этот же метод, но теперь укажем "title" в searchParam. В таком случае – метод должен вернуть только один пост, где подстрока "супер" находится в title:

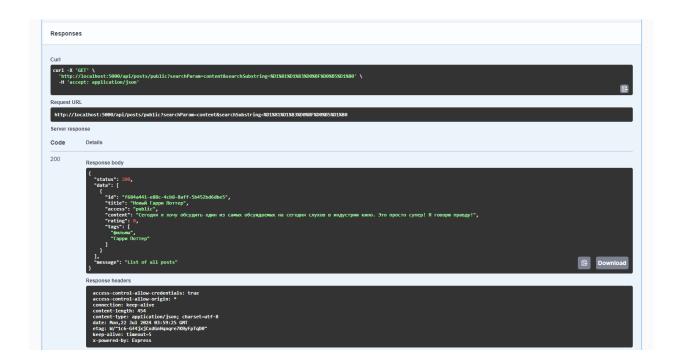




Метод отработал правильно — вернул только один пост, где подстрока "супер" находится в title.

Теперь выполним этот же метод, но теперь укажем "content" в searchParam. В таком случае – метод должен вернуть только один пост, где подстрока "супер" находится в content:





Метод отработал правильно – вернул только один пост, где подстрока "супер" находится в content, причем данный пост отличается от поста, полученного в предыдущем эксперименте, так как там "супер" искался в title, а здесь "супер" искался в content.

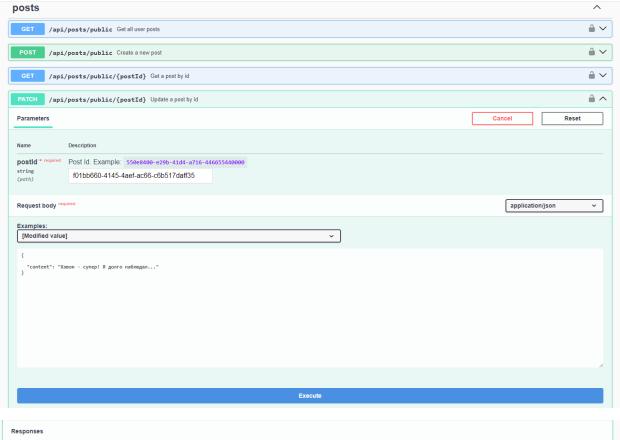
-Убедимся, что триггер работает правильно и при обновлении поста. Обновим данный пост:

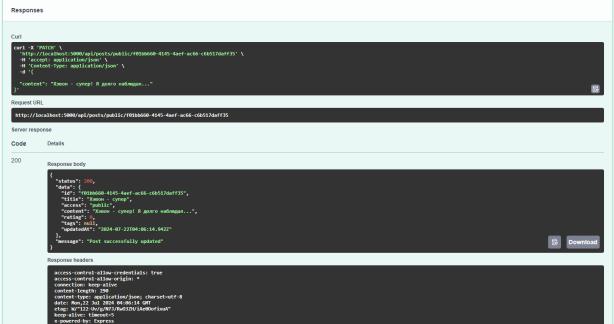
```
"id": "f01bb660-4145-4aef-ac66-c6b517daff35",
"title": "Хэвон - супер",
"access": "public",
"content": "Я влюбился в одну прекрасную девочку...",
"rating": 0,
"tags": null
```

Вот text_tsv данного поста до обновления:

```
'влюб':4B 'девочк':8B 'одн':6B 'прекрасн':7B 'супер':2A 'хэвон':1A
```

Обновим пост с помощью метода PATCH /api/posts/public/{postId}:

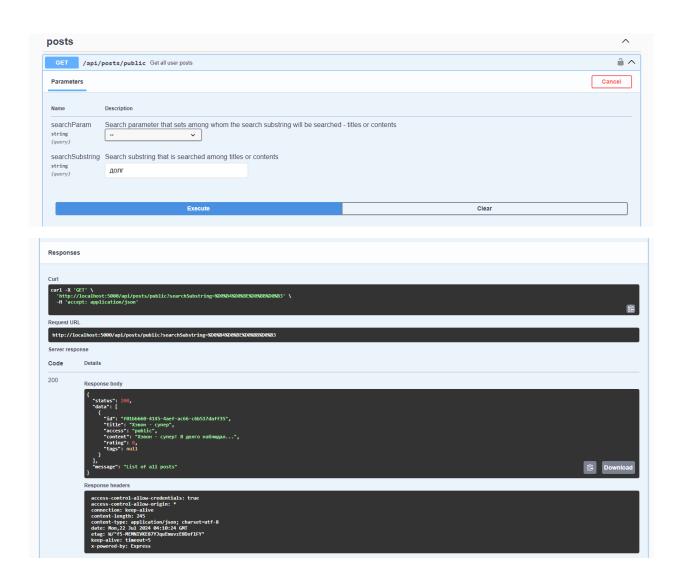




Пост успешно создался. Теперь проверим в базе данных, что text_tsv обновился:

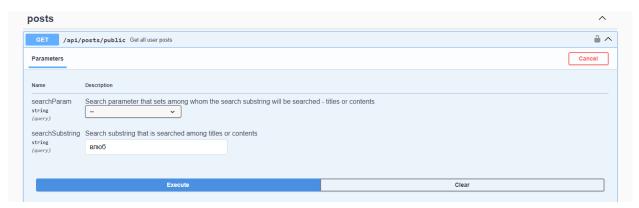
```
'долг':6В 'наблюда':7В 'супер':2А,4В 'хэвон':1А,3В
```

Как можно заметить — $text_tsv$ в базе данных действительно обновился. Попробуем получить этот пост через полнотекстовый поиск GET /api/posts/public по новому ключевому слову, который мы добавили, обновив пост:



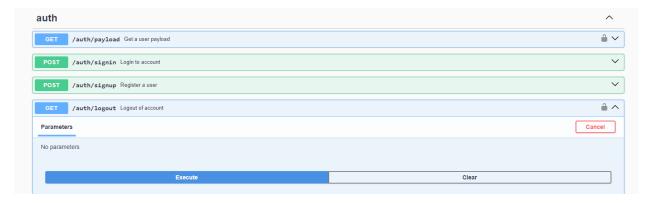
Мы получили обновленный пост через новое ключевое слово. Значит триггер при обновлении поста также работает правильно.

-Теперь убедимся, что пользователь может получить только свои посты через полнотекстовый поиск. Для этого сейчас получим случайный пост пользователя через полнотекстовый поиск GET /api/posts/public:



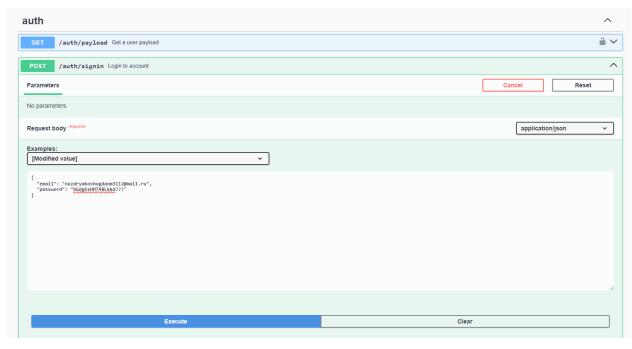
Теперь выйдем из текущего аккаунта, зайдем в другой аккаунт, создадим там пост, где будет такое же ключевое слово, по которому мы нашли пост в текущем аккаунте, а после выполним полнотекстовый поиск по этому же ключевому слову. Мы должны получить только новый созданный пост в новом аккаунте. Мы не должны получать пост из текущего аккаунта, так как каждый пользователь может получить только свои посты.

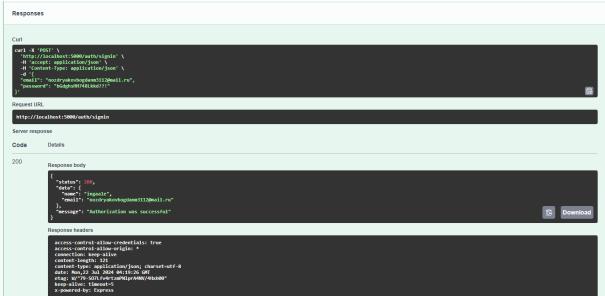
Выйдем из текущего аккаунта с помощью метода GET /auth/logout:



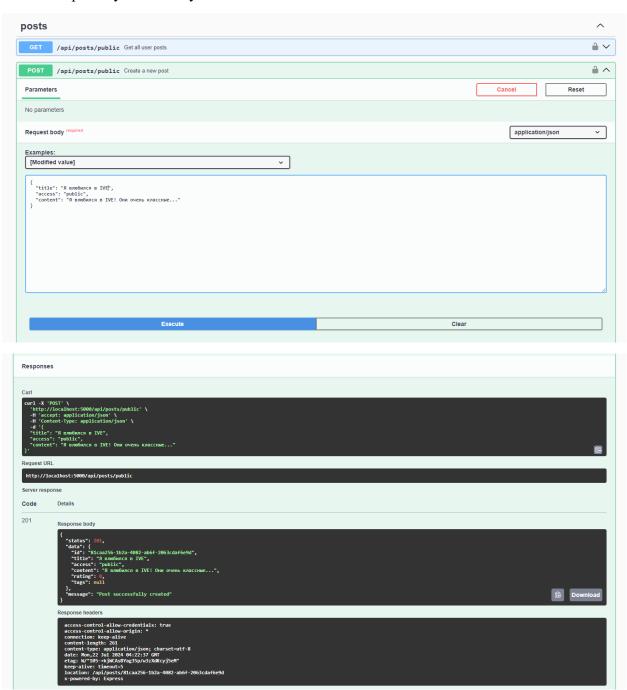


Мы успешно вышли из текущего аккаунта. Теперь войдем в новый:

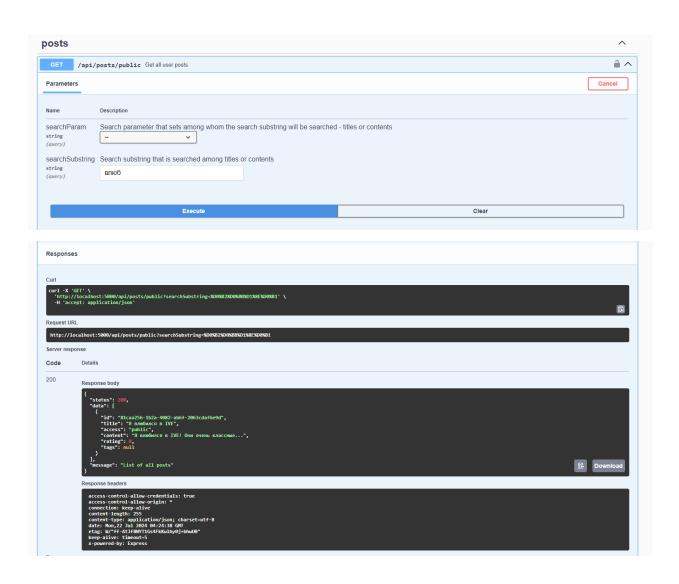




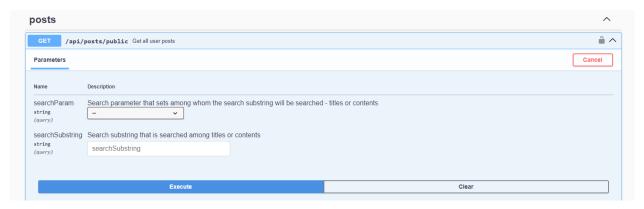
Мы успешно вошли в новый аккаунт. Теперь создадим новый пост с помощью метода POST /api/posts/public, в котором будет использоваться такое же ключевое слово, как в посте из предыдущего аккаунта:

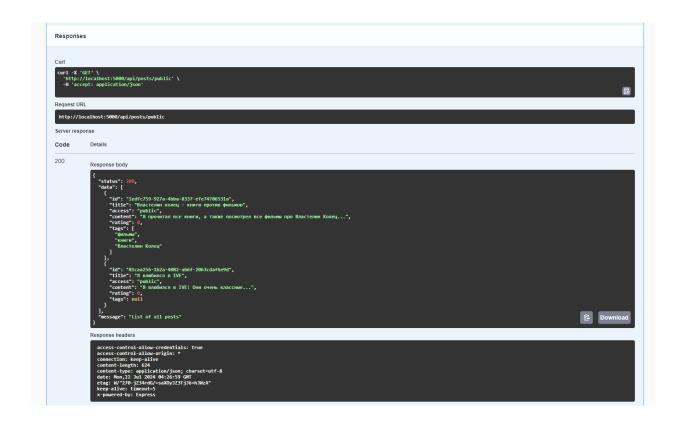


Пост создался успешно. Теперь выполним полнотекстовый поиск через метод GET /api/posts/public, в который передадим то ключевое слово:



Метод вернул нам именно новый пост из нового аккаунта. Метод не стал нам возвращать пост из предыдущего аккаунта, даже несмотря на то, что и там, и там, при полнотекстовом поиске — использовалось одно и то же ключевое слово. Выполним этот же метод, но уже без полнотекстового поиска, чтобы получить все посты пользователя:





Метод не вернул нам пост из предыдущего аккаунта. Значит, что все работает верно – пользователи могут получать только свои посты, а чужие нет.